G7 • P02 fastText 中期进展记录

G7：万燊涵 1120233197、徐铂尧 1120232601、唐源锴 1120232588、齐锴 1120231190。已完成 100 条试跑、18 次正式运行与独立核验。

论文与目标

P02 Bag of Tricks for Efficient Text Classification（Joulin 等，EACL 2017）。原文第 428页 §2.2、§3.1 与第 429 页表 1 的 AG 列：h=10 时 unigram 91.5%，bigram 92.5%；检验增加局部词序特征是否有益。分工：万燊涵论文与统稿，徐铂尧数据，唐源锴实验，齐锴评价与案例。

设置差异

缩规模部分复现：AG News 分层固定 1k / 5k / 10k 嵌套训练子集，验证 4,000，官方测试 7,600；split seed=2026，运行 seeds=17、42、2026。dim=10、epoch=5、lr=0.25、bucket=10M；softmax、CPU 单线程、无预训练和字符子词。学习率依作者脚本预先固定，未做原文验证调参。Windows 使用fasttext-wheel 0.9.2，而非直接编译附件 main。

训练量	方法	Accuracy%	Macro-F1%	训练/推理秒
1000	uni	43.53 ± 1.24	36.68 ± 2.14	0.056 / 0.046
1000	uni+bi	43.07 ± 2.52	39.21 ± 4.13	0.225 / 0.062
5000	uni	85.14 ± 0.14	85.13 ± 0.15	0.154 / 0.046
5000	uni+bi	80.04 ± 0.76	80.02 ± 0.78	0.378 / 0.063
10000	uni	87.26 ± 0.08	87.26 ± 0.08	0.270 / 0.046
10000	uni+bi	86.99 ± 0.16	86.98 ± 0.16	0.559 / 0.064

运行与逐条证据

18/18 次完成；scikit-learn 独立核验 208,800 条验证 / 测试输出。results/summary.csv 为汇总；results/runs/n10000_g1_s17/test.jsonl 与 n10000_g2_s17/test.jsonl 为典型并列输出，其他配置见 results/runs/。每条含 id、gold、pred、confidence、run_id；来源与固定样本 ID 见data/。

两例失败或边界

10k、seed=17：test:000004 野火预测，两者均判体育；test:000020 HP 服务器与盈利报道，unigram 判对，bigram 判商业。前者涉及主题识别失败，后者体现商业 / 科技边界；这些解释尚无词级归因支持。完整证据与另八例见 results/cases.md。

结论与下一项单因素实验

10k 的 bigram 准确率均值比 unigram 低 0.27 个百分点，训练时间约为 2.07 倍；不能据此否定原文全量设置。10k 与测试重复 1 条文本，统一移除后结论不变。下一项计划：固定 1k、bigram、全部划分和种子，仅将 epoch 从 5 改为 25，检验训练不足假设；该项尚未执行。